




prédiction des charges d'assurance médicales

PHASE 2

DE L'ANALYSE EXPLORATOIRE AU MOTEUR
DE PRÉDICTION INDUSTRIALISABLE

Semaine 2

WWW.DATADREAMTEAM.COM

The Future of Technology


Prédiction des Charges d'Assurance : Feuille de Route en 3 Semaines

Semaine 1 : Analyse & Insights




Analyse Exploratoire des Données (EDA)

Explorer le dataset, visualiser les distributions et les corrélations clés.



Formulation d'Hypothèses


Dégager 5 à 10 constats "métier" argumentés à partir des données.



Présentation #1 : Premiers Résultats


Partager les insights, les risques identifiés et le plan pour la semaine suivante.

Semaine 2 : Modèle de Référence



Préparation des Données

Mettre en place l'encodage, la mise à l'échelle et le protocole d'évaluation.



Entraînement de la Baseline


Créer un premier modèle de régression linéaire et analyser ses erreurs.



Présentation #2 : Modèle Initial


Montrer le pipeline de préparation et la performance du premier modèle.

Semaine 3 : Pipeline & Optimisation



Construction du Pipeline ML

Intégrer la préparation et le modèle dans un pipeline scikit-learn robuste.



Optimisation & Validation


Affiner les modèles (Ridge, Lasso) avec la validation croisée (GridSearchCV).



Présentation Finale & Livraison

Présenter les résultats finaux, une démo et les livrables du projet.

UNE FONDATION ROBUSTE : NOTRE PIPELINE DE PRÉPARATION DES DONNÉES



Chaque expériences et modèle repose sur une pipeline de traitement standardisé, garantissant la reproductibilité et l'intégrité des résultats



Étape 1: Nettoyage


Suppression des doublons (1 instance détectée).



Étape 2: Prétraitement



Utilisation d'un `ColumnTransformer` pour un traitement différencié et sans fuite de données :

- **Variables Numériques** (`age`, `bmi`, `children`) : Mise à l'échelle avec `StandardScaler`.
- **Variables Catégorielles** : Encodage avec `OneHotEncoder` (`drop='first'`) pour éviter la multicollinéarité.



Étape 3: Segmentation

Division des données : 80% Entraînement / 20% Test.



CHOIX DES MÉTRIQUES D'ÉVALUATION



Dans le cadre de la prédiction des charges médicales

la sélection des métriques, est une décision stratégique

Un rôle précis pour l'interprétation des résultats et la validation du modèle

le choix dépend de l'objectif métier.



MAE (mean absolute error)

l'erreur moyenne en dollars



R² coefficient de détermination


Mesure la qualité globale du modèle



**RMSE
Root Mean Squared
Error**

identifier les cas où le modèle se trompe fortement



La **MAE** est retenue comme métrique principale pour évaluer le modèle, la **RMSE** comme métrique complémentaire d'analyse du risque, et le **R²** comme indicateur global de performance explicative.



POINT DE DÉPART : UN MODÈLE DE RÉGRESSION LINÉAIRE SIMPLE / BASELINE



Métrique	Valeur	Interprétation Métier
MAE	4177.05 \$	L'erreur moyenne sur chaque prédiction est trop élevée.
RMSE	5956.34 \$	L'erreur quadratique est pénalisée par de grandes erreurs.
R ²	0.8069	Le modèle explique 80.7% de la variabilité des charges.



UNE AUTRE PISTE

LES RÉGULARISATIONS RIDGE ET LASSO



Nous avons testé les régularisations Ridge et lasso

L'objectif est de vérifier si ces variantes linéaires améliorent les performances

Améliore la précision et la stabilité du modèle

Régularisation Ridge

$R^2 : 0.8059$

modèle plus stable

Éviter l'overfitting

Régularisation Lasso

$R^2 : 0.8069$

modèle plus simple
et plus interprétable

Résultats des modèles – Semaine 2


Modèle	MAE	RMSE	R^2
LinearRegression	4177.05	5956.34	0.8069
Ridge	4193.89	5971.86	0.8059
Lasso	4177.12	5956.47	0.8069

aucune amélioration


la régression linéaire est notre meilleur modèle
des erreurs raisonnables

Le modèle reste simple, interprétable et robuste

LE CONSTAT : MANQUE DE CAPACITÉ DU MODÈLE À CAPTURER LES
INTÉRACTIONS COMPLEXES



La majorité des points proche de la diagonale
 une bonne tendance globale.
 dispersion croissante pour les charges élevées,
 sous-estimation marquée des valeurs extrêmes.
 erreurs importantes sur les cas extrêmes



RMSE > MAE
 présence d'erreurs importantes

MAE plus pertinente
 l'interprétation métier
 erreur moyenne en dollars.

RMSE le coût des erreurs extrêmes
 pénalise fortement les valeurs aberrantes.

MAE $\approx$ RMSE
Peu de grosses erreurs


RMSE $\gg$ MAE
existe des grosses erreurs

AMÉLIORATION DU MODÈLE : FEATURE ENGINEERING



Pour tenter d'améliorer notre modèle de prédiction des charges d'assurance, nous allons créer quelques nouvelles features

construction de 3 variables Synthétiques



1. Interaction `bmi \* smoker`




Raison d'être : Capture l'effet multiplicateur du tabac sur les coûts liés à l'IMC. C'est la variable qui modélise l'explosion des coûts.

2. Indicateur `is\_obese\_smoker`



Raison d'être : Crée un drapeau binaire pour isoler spécifiquement ce segment à très haut risque et permettre au modèle de lui assigner un poids unique.

3. Terme Quadratique `age²`



Raison d'être : Modélise l'accélération (et non la simple augmentation linéaire) des coûts de santé avec le vieillissement avancé.

AMÉLIORATION DU MODÈLE DE PRÉDICTION DES CHARGES D'ASSURANCE



L'ajout de nos 3 variables d'interaction transforme radicalement la performance du modèle

Métrique	Baseline	Modèle Final	Impact
R²	0.8069	0.9324	↗ +15.5%
MAE	4177 \$	~1981 \$	↓ -52.6%
RMSE	5956 \$	~3154 \$	↓ -47.0%

Impact massif de l'interaction bmi * smoker permet de passer d'un R² de 0.80 à 0.93. Le modèle capture enfin le coût exponentiel des fumeurs ayant un IMC élevé.

Le modèle ne sous estime plus les charges élevées

illustre l'amélioration des performances obtenue grâce au Feature Engineering


Le bond du R² de 0.81 à 0.93 permet de réduire drastiquement l'erreur moyenne et de mieux cibler les comportements extremes .

LA SOLUTION : LA PUISSANCE D'UN MODÈLE LINÉAIRE ENRICHIS



La performance de notre modèle finale démontre une leçon essentielle
une compréhension des données
un feature engineering intelligent
permet à un modèle simple
de rivaliser, voire de surpasser des approches plus complexes

Prédiction vs Réalité




- ◆ **Tendance générale** : Bon ajustement pour charges < 30k.
- ◆ **Échec majeur** : Sous-prédiction massive pour charges > 30k.
- ◆ **Segment critique** : Fumeurs obèses
- ◆ **Conclusion** : Effet multiplicatif non capté → besoin de features non linéaires ou modèle avancé.




**Performance de
Pointe ($R^2=0.93$)**

Prédire les Frais Médicaux : D'un Modèle de Base à la Haute Précision


Le Problème :
Un Modèle de Base Insuffisant




La Solution : L'Ingénierie des Caractéristiques Ciblée



Résultat :
L'Erreur Moyenne est Divisée par Deux !



Rivalise avec des approches plus complexes tout en restant 100% Explicable



PROCHAINE ÉTAPE : DE LA VALIDATION À LA MISE EN PRODUCTION




La validation du modèle

Les performances dépassent les objectifs fixés

Le modèle est prêt à être testé et intégré dans les processus opérationnels

Semaine 3 : Pipeline & Optimisation



Construction
du Pipeline ML

Optimisation
& Validation

Présentation
Finale &



Industrialisation

Modèle final


déploiement fiable



Intégration et Simulation

Intégration prochaine dans le dashboard
streamlit existant

Simulation des charges en temps
réel





MERCI

STAY CONNECTED. STAY AHEAD. STAY TECHNOLOGICAL

Rdv semaine 3

WWW.DATADREAMTEAM.COM

The Future of Technology